

# Strings

Jorge Loría

## Strings básicos

Ya hemos trabajado con strings dentro de dataframes, sin embargo no hemos tenido la oportunidad de trabajarlos por su cuenta. Para esto usamos el paquete:

```
library(stringr)
```

## Strings básicos

Ya hemos trabajado con strings dentro de dataframes, sin embargo no hemos tenido la oportunidad de trabajarlos por su cuenta. Para esto usamos el paquete:

```
library(stringr)
```

Una parte es aprender sobre expresiones regulares en su generalidad, y otra parte es aprender sobre las funciones específicas que trabaja `stringr`.

## Expresiones básicas

Las barras inclinadas: `\`, tienen diversos propósitos dentro de los strings. Por ejemplo, si se quiere incluir una comilla en un string antes se debe poner `\`. `'\''`. Además, se puede hacer `'''`, `"""`, `"\""`, etc...

## Expresiones básicas

Las barras inclinadas: \, tienen diversos propósitos dentro de los strings. Por ejemplo, si se quiere incluir una comilla en un string antes se debe poner \. '\'. Además, se puede hacer ''', '''', "\"", etc. . .

Otra manera en que se suelen usar es para ejecutar caracteres tipo **UTF-8**, por ejemplo:

```
s1 <- '\u00a2'
```

## Expresiones básicas

Las barras inclinadas: \, tienen diversos propósitos dentro de los strings. Por ejemplo, si se quiere incluir una comilla en un string antes se debe poner \. '\'. Además, se puede hacer ''', '''', "\"", etc...

Otra manera en que se suelen usar es para ejecutar caracteres tipo **UTF-8**, por ejemplo:

```
s1 <- '\u00a2'
```

Si se quiere ver el símbolo generado, se puede usar la función `writeLines`:

```
writeLines(s1)
```

```
## ¢
```

## Dos expresiones muy frecuentes

Dos expresiones que aparecen en *tooooo* lado, porque las usamos en todo lado son: `'\t'` y `'\n'`. Que representan, un *tab* y una línea nueva, respectivamente.

Ejercicio: Use `writeLines` para ver cómo se ven estos strings: `'a\tack'`, y `'bue\nno'`.

## Funciones básicas

Inicialmente solo vamos a trabajar con `str_extract`, pero también se puede considerar `str_view` y ver las coincidencias en el **Viewer** de RStudio en una forma más cómoda.



## Funciones básicas

Inicialmente solo vamos a trabajar con `str_extract`, pero también se puede considerar `str_view` y ver las coincidencias en el **Viewer** de RStudio en una forma más cómoda.

```
f1 <- c("piña", "naranja", "limón")  
str_match(f1, "an")
```

```
##      [,1]  
## [1,] NA  
## [2,] "an"  
## [3,] NA
```

## Expresiones regulares

*Cuando usted tiene un problema y lo ataca con una expresión regular, entonces tiene dos problemas.*

Por ejemplo, la expresión regular para calzar un correo electrónico.

## Expresiones regulares

*Cuando usted tiene un problema y lo ataca con una expresión regular, entonces tiene dos problemas.*

Por ejemplo, la expresión regular para calzar un correo electrónico.

```
f2 <- c("manzana", "banano", "pera")  
str_match(f2, "n")
```

```
##      [,1]  
## [1,] "n"  
## [2,] "n"  
## [3,] NA
```

## Anclas




Figure 1: Otro tipo de ancla

# Anclas

Hay dos anclas:

- ▶ '^': lo que lo sigue es lo que va al inicio del string.
- ▶ '\$': lo que viene antes es lo que va al final del string.

# Anclas

Hay dos anclas:

- ▶ '^': lo que lo sigue es lo que va al inicio del string.
- ▶ '\$': lo que viene antes es lo que va al final del string.

Para recordarlo: *'Begin with power, you end with money'*

# Anclas

Hay dos anclas:

- ▶ `'^'`: lo que lo sigue es lo que va al inicio del string.
- ▶ `'$'`: lo que viene antes es lo que va al final del string.

Para recordarlo: *'Begin with power, you end with money'*

Por ejemplo, si quiero obtener las palabras que comiencen con 'a', pongo: `'^a'` y si quiero las que terminan con 'a', pongo `'a$'`.

## Ejercicio

La función que indica si un string contiene o no (booleano) una expresión, es `str_detect`.

Sabiendo esto, y usando `ggplot2::luv_colours$col`, identifique cuántos colores comienzan con 'blue', y cuantas terminan con 'red'.



## Otras expresiones

- ▶ `'.'`: cualquier caracter.
- ▶ `'\\d'`: dígitos
- ▶ `'\\s'`: espacios en blanco
- ▶ `'[asdf]'`: cualquiera de a, s, d ó f.
- ▶ `'[^qwer]'`: cualquiera que **NO** sea q, w, e ó r.
- ▶ `asdf|uiop`: si es asdf ó uiop

## Por ejemplo

Si queremos ver los colores que comienzan con 'w' o 't' y luego va una 'h', podemos hacer:

```
library(tidyverse)
luv_colours %>%
  filter(str_detect(col, '^[wt]h'))
```

##		L	u	v	col
## 1		9341.570	-3.370649e-12	0.000	white
## 2		7646.660	1.307466e+03	-1672.026	thistle
## 3		8724.731	1.518395e+03	-1941.769	thistle1
## 4		8255.476	1.436705e+03	-1837.301	thistle2
## 5		7327.193	1.268391e+03	-1622.057	thistle3
## 6		5372.190	9.130116e+02	-1167.587	thistle4
## 7		8438.146	1.698468e+03	3356.759	wheat
## 8		8711.263	1.759674e+03	3482.715	wheat1
## 9		8251.864	1.637730e+03	3290.972	wheat2

[]

Los paréntesis cuadrados tienen una peculiaridad: si se incluye un caracter especial adentro, van a dar una coincidencia aunque no se 'escape':

```
str_extract(c('au.ge', 'Hola.', 'ca.lza'), 'a[.]')
```

```
## [1] NA    "a." "a."
```

[]

Los paréntesis cuadrados tienen una peculiaridad: si se incluye un caracter especial adentro, van a dar una coincidencia aunque no se 'escape':

```
str_extract(c('au.ge', 'Hola.', 'ca.lza'), 'a[.]')
```

```
## [1] NA    "a." "a."
```

Repita lo anterior, pero sin usar los paréntesis cuadrados.

[]

Dentro de los paréntesis cuadrados se pueden indicar más cosas, como que sea parte del alfabeto, usando: [A-z]. Por ejemplo, si queremos buscar todos los colores que terminan con una letra del alfabeto, usamos:

```
luv_colours %>%  
  filter(str_detect(col, "[A-z]$"))
```

Si queremos que solo coincida en letras minúsculas, cambiamos la 'A' por una 'a'.

[ ]

Dentro de los paréntesis cuadrados se pueden indicar más cosas, como que sea parte del alfabeto, usando: [A-z]. Por ejemplo, si queremos buscar todos los colores que terminan con una letra del alfabeto, usamos:

```
luv_colours %>%  
  filter(str_detect(col, "[A-z]$"))
```

Si queremos que solo coincida en letras minúsculas, cambiamos la 'A' por una 'a'. Y si solo queremos las mayúsculas, cambiamos la 'z' por una 'Z'. Además, podemos preguntar por dígitos, usando [:digit:].

[ ]

Dentro de los paréntesis cuadrados se pueden indicar más cosas, como que sea parte del alfabeto, usando: [A-z]. Por ejemplo, si queremos buscar todos los colores que terminan con una letra del alfabeto, usamos:

```
luv_colours %>%  
  filter(str_detect(col, "[A-z]$"))
```

Si queremos que solo coincida en letras minúsculas, cambiamos la 'A' por una 'a'. Y si solo queremos las mayúsculas, cambiamos la 'z' por una 'Z'. Además, podemos preguntar por dígitos, usando [:digit:]. Si buscamos todos los colores que terminen con una letra y un número, hacemos:

```
luv_colours %>%  
  filter(str_detect(col, "[A-z][:digit:]+$"))
```

##		L	u	v	col
## 1	8935.2255	1.065698e+03	1.674595e+03	antiquewhite1	
## 2	8452.4228	1.014211e+03	1.602522e+03	antiquewhite2	

Es un o, simple y sencillo. El problema es que tiene prioridad sobre las demás expresiones, entonces, uno puede usar ( paréntesis ) para poder señalar el orden de prioridad. Por ejemplo:

```
cas <- c('cas', 'caza', 'casa', 'zorro')  
str_detect(cas, 'ca(s|z)')
```

```
## [1] TRUE TRUE TRUE FALSE
```



Es un o, simple y sencillo. El problema es que tiene prioridad sobre las demás expresiones, entonces, uno puede usar ( paréntesis ) para poder señalar el orden de prioridad. Por ejemplo:

```
cas <- c('cas', 'caza', 'casa', 'zorro')  
str_detect(cas, 'ca(s|z)')
```

```
## [1] TRUE TRUE TRUE FALSE
```

Si no le ponemos paréntesis:

```
str_detect(cas, 'cas|z')
```

```
## [1] TRUE TRUE TRUE TRUE
```

## Ejercicios

- ▶ ¿Cuántos colores terminan con un 4?
- ▶ ¿Hay algún color que comience con un dígito?
- ▶ ¿Cuántos colores hay que sean exactamente 3 caracteres cualesquiera, y el cuarto y último sea un número?

## Ejercicios

- ▶ ¿Cuántos colores terminan con un 4?
- ▶ ¿Hay algún color que comience con un dígito?
- ▶ ¿Cuántos colores hay que sean exactamente 3 caracteres cualesquiera, y el cuarto y último sea un número?

## Ejercicios

- ▶ ¿Cuántos colores terminan con un 4?
- ▶ ¿Hay algún color que comience con un dígito?
- ▶ ¿Cuántos colores hay que sean exactamente 3 caracteres cualesquiera, y el cuarto y último sea un número?

98

FALSE

## Ejercicios

- ▶ ¿Cuántos colores terminan con un 4?
- ▶ ¿Hay algún color que comience con un dígito?
- ▶ ¿Cuántos colores hay que sean exactamente 3 caracteres cualesquiera, y el cuarto y último sea un número?

98

FALSE

8

## Repeticiones



Figure 2: Otro tipo de repeticiones

## Repeticiones

Muchas veces a uno le interesa ver si un caracter apareció cierta cantidad de veces. Para esto usamos:

- ▶ `'?'`: 0 ó 1 vez
- ▶ `'+'`: 1 vez o más
- ▶ `'*'`: 0 veces o más
- ▶ `'{n}'`: exactamente  $n$  veces
- ▶ `'{n,}'`: al menos  $n$  veces
- ▶ `'{n,m}'`: entre  $n$  y  $m$  veces

## Repeticiones, ejemplo:

Por ejemplo, si se quieren revisar si tienen dos o más zetas:

```
f3 <- c('pizza', 'grizzly', 'sizzler', 'drizzler', 'caza')  
str_extract(f3, pattern = 'z{2,}')
```

```
## [1] "zz"  "zz"  "zz"  "zzz" NA
```

O si se quiere revisar entre 1 y cuatro:

```
str_extract(f3, pattern = 'z{1,4}?')
```

```
## [1] "z"  "z"  "z"  "z"  "z"
```



## Ejercicio

- ▶ Encuentre todos los colores que comiencen con al menos 3 consonantes.
- ▶ Encuentre todos los colores que tengan al menos dos números seguidos.

## Referenciar

Muchas veces a uno le interesa revisar un patrón más de una vez, para esto se pueden 'agrupar' usando los paréntesis, y al usar '\\1' se hace referencia a ese valor.

```
str_view(fruit, "(..)\\1", match = TRUE)
```

Si se quieren los colores que comiencen y terminen con la misma letra, se puede hacer:

```
luv_colours %>%  
  filter(str_detect(col, "^(.).*\\1$")) %>%  
  select(col)
```

```
##           col  
## 1 darkgoldenrod  
## 2   darkorchid  
## 3    darkred  
## 4   lightcoral  
## 5    mintcream  
## 6   papayawhip
```

## Más grupos

Si queremos una expresión que haga referencia a más de un grupo, podemos usar otros números.

```
luv_colours %>%  
  filter(str_detect(col, "^(.).*(.).*\\2.*\\1$")) %>%  
  select(col)
```

```
##           col  
## 1 darkgoldenrod  
## 2   darkorchid  
## 3     darkred  
## 4   papayawhip
```

## Más grupos

Si queremos una expresión que haga referencia a más de un grupo, podemos usar otros números.

```
luv_colours %>%  
  filter(str_detect(col, "^(.).*(.).*\\2.*\\1$")) %>%  
  select(col)
```

```
##           col  
## 1 darkgoldenrod  
## 2   darkorchid  
## 3     darkred  
## 4   papayawhip
```

¿Qué buscamos si en la expresión anterior cambiamos el 1 por el 2 y viceversa?

## Ejercicio

- ▶ Encuentre todos los colores que tengan una vocal repetida y terminen con una no-vocal.
- ▶ Encuentre todos los colores que terminen con dos números iguales.

Buscar

Buscar



Figure 3: Pero no con google

## Buscar alrededor

Algunas veces a uno le interesa que coincida un valor que está próximo, pero que no sea parte del resultado. Para esto usamos los operadores 'look around':

- ▶ `'(?:=algo)'`: revisa si 'algo' está justo delante
- ▶ `'(?:!puede)'`: revisa si 'puede' NO está justo delante
- ▶ `'(?:<=estar)'`: revisa si 'estar' está justo atrás
- ▶ `'(?:<!oNO)'`: revisa si 'oNO' NO está justo atrás



## Buscar alrededor

```
montos <- c('$100', '186 dolares', '295 dolares', '$1580')  
str_detect(montos, '\\d+\\s(?:=dolares)')
```

```
## [1] FALSE  TRUE  TRUE FALSE
```

## Buscar alrededor

```
montos <- c('$100', '186 dolares', '295 dolares', '$1580')  
str_detect(montos, '\\d+\\s(?:dolares)')
```

```
## [1] FALSE TRUE TRUE FALSE
```

Todavía no lo corran. Veánlo y piensen porqué da este resultado:

```
str_detect(montos, '(?!\\$)\\d{3,}')
```

```
## [1] FALSE TRUE TRUE TRUE
```

## Buscar alrededor

```
montos <- c('$100', '186 dolares', '295 dolares', '$1580')  
str_detect(montos, '\\d+\\s(?:dolares)')
```

```
## [1] FALSE TRUE TRUE FALSE
```

Todavía no lo corran. Veánlo y piensen porqué da este resultado:

```
str_detect(montos, '(?!\\$)\\d{3,}')
```

```
## [1] FALSE TRUE TRUE TRUE
```

¿Cómo podríamos modificarlo para que solo calce con los que NO tienen el símbolo de dólares?

# Herramientas

# Herramientas



Figure 4: Herramientas!

# Herramientas

- ▶ `str_view`: para ver

# Herramientas

- ▶ `str_view`: para ver
- ▶ `str_detect`: identifica si contiene la expresión

# Herramientas

- ▶ `str_view`: para ver
- ▶ `str_detect`: identifica si contiene la expresión
- ▶ `str_match`: toma la parte de la expresión que coincide, lo pone en forma matricial



# Herramientas

- ▶ `str_view`: para ver
- ▶ `str_detect`: identifica si contiene la expresión
- ▶ `str_match`: toma la parte de la expresión que coincide, lo pone en forma matricial
- ▶ `str_extract`: toma la parte de la expresión que coincide, lo pone en un vector

# Herramientas

- ▶ `str_view`: para ver
- ▶ `str_detect`: identifica si contiene la expresión
- ▶ `str_match`: toma la parte de la expresión que coincide, lo pone en forma matricial
- ▶ `str_extract`: toma la parte de la expresión que coincide, lo pone en un vector
- ▶ `str_subset`: toma los strings que cumplen la condición, es como combinar el filter y el detect

# Herramientas

- ▶ `str_view`: para ver
- ▶ `str_detect`: identifica si contiene la expresión
- ▶ `str_match`: toma la parte de la expresión que coincide, lo pone en forma matricial
- ▶ `str_extract`: toma la parte de la expresión que coincide, lo pone en un vector
- ▶ `str_subset`: toma los strings que cumplen la condición, es como combinar el filter y el detect
- ▶ `str_count`: cuenta cuantas veces en el string se dio la coincidencia

## subset

Por ejemplo, si yo quiero tomar únicamente los colores que comienzan con una no-vocal, y terminan con esa misma letra, hago:

```
luv_colours$col %>%  
  str_subset(pattern = "^([^\aeiou]).*\1$")
```

```
## [1] "darkgoldenrod" "darkorchid"    "darkred"       "lightcoral"  
## [5] "mintcream"     "papayawhip"
```

## Quijote

Vamos a usar el primer capítulo del Quijote, que está en formato txt, y para leerlo usamos:

## Quijote

Vamos a usar el primer capítulo del Quijote, que está en formato txt, y para leerlo usamos:

```
quijote <- readLines('Quijote_Capitulo_Primer.txt',  
                    encoding = 'UTF-8')
```

## Quijote

Vamos a usar el primer capítulo del Quijote, que está en formato txt, y para leerlo usamos:

```
quijote <- readLines('Quijote_Capitulo_Primer.txt',
                     encoding = 'UTF-8')
```

Si queremos ver cuantas veces por linea aparece 'con', usamos:

```
quijote %>% str_count(pattern = 'con')
```

```
##      [1] 0 1 0 0 0 0 0 0 0 0 1 1 1 1 0 0 1 0 0 0 1 0 0 0 0 1 0 0 0 0 0 0 0 0
##     [36] 0 1 0 0 0 0 0 1 0 1 1 0 0 2 1 0 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 1
##     [71] 0 0 1 0 1 0 0 0 0 0 0 1 0 1 0 0 0 0 1 0 0 0 0 0 0 0 0 1 0 0 1 1 0
##    [106] 0 0 0 0 1 0 0 1 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 2 0 0 1 1 0 0 1 0 0
##   [141] 0 2 0 0 0 1 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0 0
```

all

Es posible que se den múltiples coincidencias dentro de una misma frase que uno indique, si uno ocupara todas, puede hacer:

```
quijote %>%  
  str_extract_all('de',simplify = TRUE)
```

```
##           [,1] [,2] [,3] [,4]  
## [1,] ""      ""      ""      ""  
## [2,] "de"    "de"    ""      ""  
## [3,] "de"    ""      ""      ""  
## [4,] ""      ""      ""      ""  
## [5,] ""      ""      ""      ""  
## [6,] "de"    "de"    ""      ""  
## [7,] "de"    "de"    ""      ""  
## [8,] "de"    ""      ""      ""  
## [9,] ""      ""      ""      ""  
## [10,] "de"   ""      ""      ""
```



all

¿Qué pasa si no pone `simplify = TRUE`?

all

¿Qué pasa si no pone `simplify = TRUE`?

También está `str_match_all`, que hace algo similar, pero no tiene `simplify`, y da un formato distinto:

```
quijote %>% # Qué puede reemplazar a {0,1}?  
  str_match_all('don{0,1}')
```

```
## [[1]]  
##      [,1]  
##  
## [[2]]  
##      [,1]  
##  
## [[3]]  
##      [,1]  
## [1,] "don"  
##
```

## sub

Una función particularmente útil, es `str_sub`, que toma la porción del string que se le indica, con base en el número de letras:

```
f3 %>%  
  str_sub(start = 3,end = 5)
```

```
## [1] "zza" "izz" "zzl" "izz" "za"
```

¿Qué pasa si el `end` queda después de la última letra?

## sub

Una función particularmente útil, es `str_sub`, que toma la porción del string que se le indica, con base en el número de letras:

```
f3 %>%  
  str_sub(start = 3,end = 5)
```

```
## [1] "zza" "izz" "zzl" "izz" "za"
```

¿Qué pasa si el `end` queda después de la última letra?

No agrega más :)

## replace

Reemplaza. Modifica en la las partes donde haya coincidencia con el patrón, y reemplaza con lo que se indique:

```
f3 %>%  
  str_replace(pattern = 'z{1,2}',  
              replacement = 'AAA')
```

```
## [1] "piAAAa"      "griAAAlly"   "siAAAler"    "driAAAzler"  "caAAAa"
```

all

Esta función también viene con una versión `all`, y hace el reemplazo en todos los lugares donde haya coincidencia:

```
f3 %>%  
  str_replace_all(pattern = 'z{1,2}',  
                  replacement = '0E0E')
```

```
## [1] "pi0E0Ea"      "gri0E0Ely"     "si0E0Eler"     "dri0E0E0E0Eler"  
## [5] "ca0E0Ea"
```

str\_c

Pega vectores... de forma vectorial:

```
str_c(1:13, letters, sep = '|-k-|')
```

```
## [1] "1|-k-|a" "2|-k-|b" "3|-k-|c" "4|-k-|d" "5|-k-|e" "6|-k-|f"
## [7] "7|-k-|g" "8|-k-|h" "9|-k-|i" "10|-k-|j" "11|-k-|k" "12|-k-|l"
## [13] "13|-k-|m" "1|-k-|n" "2|-k-|o" "3|-k-|p" "4|-k-|q" "5|-k-|r"
## [19] "6|-k-|s" "7|-k-|t" "8|-k-|u" "9|-k-|v" "10|-k-|w" "11|-k-|x"
## [25] "12|-k-|y" "13|-k-|z"
```

str\_c

Pega vectores... de forma vectorial:

```
str_c(1:13, letters, sep = '|-k-|')
```

```
## [1] "1|-k-|a" "2|-k-|b" "3|-k-|c" "4|-k-|d" "5|-k-|e" "6|-k-|f"
## [7] "7|-k-|g" "8|-k-|h" "9|-k-|i" "10|-k-|j" "11|-k-|k" "12|-k-|l"
## [13] "13|-k-|m" "1|-k-|n" "2|-k-|o" "3|-k-|p" "4|-k-|q" "5|-k-|r"
## [19] "6|-k-|s" "7|-k-|t" "8|-k-|u" "9|-k-|v" "10|-k-|w" "11|-k-|x"
## [25] "12|-k-|y" "13|-k-|z"
```

Vamos a 'pegar' todo el capítulo en un solo string:

```
quijote1 <- str_c(quijote, collapse = ' ')
```



## Más herramientas

- ▶ `str_length`: indica la cantidad de letras que tiene una palabra  
`str_length('mas')` da 3

## Más herramientas

- ▶ `str_length`: indica la cantidad de letras que tiene una palabra  
`str_length('mas')` da 3
- ▶ `str_to_lower`: transforma los strings a letras minúsculas `str_to_lower('No es AbuRrId0')` da: no es aburrido

## Más herramientas

- ▶ `str_length`: indica la cantidad de letras que tiene una palabra  
`str_length('mas')` da 3
- ▶ `str_to_lower`: transforma los strings a letras minúsculas `str_to_lower('No es AbuRrId0')` da: no es aburrido
- ▶ `str_to_upper`: pasa a mayúsculas `str_to_upper('Algo interesante')` da: ALGO INTERESANTE

## Más herramientas

- ▶ `str_length`: indica la cantidad de letras que tiene una palabra  
`str_length('mas')` da 3
- ▶ `str_to_lower`: transforma los strings a letras minúsculas `str_to_lower('No eS AbuRrId0')` da: no es aburrido
- ▶ `str_to_upper`: pasa a mayúsculas `str_to_upper('Algo interesante')` da: ALGO INTERESANTE
- ▶ `str_to_title`: pone la primera letra de cada palabra en mayúscula y las demás a minúscula, `str_to_title('eSte Es un tiTuLo')` da: Este Es Un Titulo

## Más herramientas

- ▶ `str_length`: indica la cantidad de letras que tiene una palabra  
`str_length('mas')` da 3
- ▶ `str_to_lower`: transforma los strings a letras minúsculas `str_to_lower('No eS AbuRrId0')` da: no es aburrido
- ▶ `str_to_upper`: pasa a mayúsculas `str_to_upper('Algo interesante')` da: ALGO INTERESANTE
- ▶ `str_to_title`: pone la primera letra de cada palabra en mayúscula y las demás a minúscula, `str_to_title('eSte Es un tiTuLo')` da: Este Es Un Titulo
- ▶ `str_replace_na`: quita los NAs y los transforma en un string que dice 'NA'

str\_split

## str\_split

Se usa para separar strings según la expresión que se indique. En este caso, vamos a separar el resultado anterior, por medio de los espacios:

```
quijote1 %>%  
  str_split('\\s')
```

Con lo que se obtienen todas las palabras del primer capítulo del Quijote :)

## Ejercicios

- ▶ ¿Cuántos números aparecen en el capítulo del Quijote?



## Ejercicios

- ▶ ¿Cuántos números aparecen en el capítulo del Quijote?
- ▶ ¿Cuántas veces aparece 'ella' en el capítulo del quijote? ¿Y 'el'? ¿Como puede asegurarse que no sea un 'ella'?

## Ejercicios

- ▶ ¿Cuántos números aparecen en el capítulo del Quijote?
- ▶ ¿Cuántas veces aparece 'ella' en el capítulo del quijote? ¿Y 'el'? ¿Como puede asegurarse que no sea un 'ella'?
- ▶ ¿Como se lee la segunda línea si modificamos las vocales por por 'u'?

## Ejercicios

- ▶ ¿Cuántos números aparecen en el capítulo del Quijote?
- ▶ ¿Cuántas veces aparece 'ella' en el capítulo del quijote? ¿Y 'el'? ¿Como puede asegurarse que no sea un 'ella'?
- ▶ ¿Como se lee la segunda línea si modificamos las vocales por por 'u'?
- ▶ Cree un dataframe con las palabras del capítulo del quijote. Elimine las de longitud cero y las demás páselas a minúscula. Cuente cuantas veces aparece cada palabra, e identifique cuantas de las palabras observadas comienzan con 'qu'. ¿Siempre que aparece una 'q' aparece una 'u' después? ¿Qué sucede más una 'qui' o una 'que'?